Plano de Pesquisa

Análise Comparativa de Técnicas de Melhoramento de Imagem em Exames de Videofluoroscopia da Deglutição

Sumário

Apresentação 1

Fase 0 — Preparação 2

Fase 1 — Caracterização da base e congelamento do protocolo 3

Protocolo transversal I — Otimização de hiperparâmetros 6

Protocolo transversal II — Análise estatística 8

Fase 2 — Catálogo de realce clássico e seleção de parâmetros 10

Fase 3 — Avaliação da qualidade da imagem 12

Fase 4 — Redução de ruído aprendida a partir dos próprios dados 13

Fase 5 — Impacto na segmentação, com desenho fatorial 14

Fase 6 — Realce aprendido dentro da rede de segmentação 16

Fase 7 — Teste final, síntese e escrita 17

Ordem de execução e prioridade de cortes 18

Riscos e mitigação 19

Entregas por fase 19

Apresentação

Este documento descreve o plano de pesquisa para a análise comparativa de técnicas de melhoramento de imagem aplicadas a exames de videofluoroscopia da deglutição (VFSS). O objetivo é avaliar o impacto dessas técnicas na qualidade visual das imagens e no desempenho de redes neurais aplicadas à segmentação de estruturas anatômicas relevantes ao processo de deglutição.

O plano sobe um degrau por vez: caracterizar a imagem, aplicar realce clássico, aprender o realce a partir dos próprios dados, e por fim deixar a rede de segmentação aprender o realce sozinha. Cada fase entrega resultado próprio, e o protocolo estatístico é definido antes de rodar qualquer experimento.

Fase 0 — Preparação

Objetivo: entender a física da imagem e montar infraestrutura reprodutível.

Fundamentação

É preciso entender por que a imagem de VFSS é ruim. A dose baixa de radiação implica poucos fótons por pixel, o que gera ruído de natureza **Poisson**: o desvio padrão do ruído cresce com a raiz da intensidade, ou seja, o ruído não é uniforme ao longo da imagem. Somado a isso há um ruído eletrônico gaussiano do detector.

Essa distinção não é um detalhe. Filtros clássicos como o gaussiano e o BM3D supõem ruído gaussiano uniforme e só funcionam bem depois de uma transformação estabilizadora de variância (transformação de Anscombe).

Leitura mínima

- Capítulos de realce e restauração em Gonzalez & Woods, *Digital Image Processing*
- Uma revisão sobre análise automática de exames VFSS
- Dois artigos de redução de ruído em fluoroscopia
- Krull et al. (2019), *Noise2Void: Learning Denoising from Single Noisy Images*

Infraestrutura obrigatória

Estabelecida desde o primeiro dia:

- Repositório com controle de versão
- Arquivo de configuração por experimento (nenhum parâmetro escrito no meio do código)
- Registro automático de métricas
- Sementes aleatórias fixas e ambiente com versões de biblioteca travadas

Entrega: documento de duas páginas com a definição do problema, e um pipeline que lê um vídeo, extrai os quadros e grava resultados em formato padronizado.

Fase 1 — Caracterização da base e congelamento do protocolo

Esta é a fase que determina se o trabalho todo será válido. Nada aqui pode ser alterado depois.

1.1 Inventário e caracterização

Levantar: número de **pacientes**, número de vídeos por paciente, quadros por vídeo, resolução, taxa de quadros, profundidade de bits, quantos quadros possuem anotação e a origem de cada exame. A contagem de pacientes é a mais importante das três, porque é ela que define o tamanho amostral de todo o trabalho.

Verificar também se algum paciente aparece nas duas bases, ou em sessões diferentes com identificadores distintos. Duplicata de paciente não detectada é vazamento silencioso, e nenhuma divisão por grupo protege contra ela.

Bases coletadas em instituições diferentes usam aparelhos e protocolos diferentes, o que provavelmente aparece nos histogramas.

Registrar o histograma e a faixa dinâmica efetivamente ocupada por vídeo.

1.2 Estimação do modelo de ruído

Procedimento concreto:

1. Dividir a imagem em blocos pequenos e homogêneos.
2. Calcular média e variância local de cada bloco.
3. Plotar variância contra média.

Se a relação for aproximadamente linear, o modelo Poisson-gaussiano se confirma, e o coeficiente angular estima o ganho do detector. Fazer isso separadamente para cada conjunto de dados.

Esse resultado alimenta duas decisões posteriores: quais filtros exigem transformação de Anscombe, e qual ruído sintético usar nos controles.

1.3 Divisão dos dados (congelada e documentada)

Os dados têm três níveis encaixados: quadro dentro de vídeo, vídeo dentro de paciente. O mesmo paciente costuma ter mais de um vídeo, e é isso que determina o critério de divisão.

A divisão é por paciente, nunca por vídeo e nunca por quadro. Dois vídeos do mesmo paciente mostram a mesma anatomia: a mesma morfologia das vértebras C2 a C4, o mesmo biotipo, com frequência a mesma sessão e a mesma configuração de aparelho. Uma rede que treinou em um desses vídeos pode memorizar o formato daquelas vértebras e acertar o outro sem ter aprendido nada generalizável. Dividir por vídeo vaza exatamente a estrutura que se pretende segmentar. Na prática, o agrupamento usa o identificador do paciente como chave de grupo, no estilo `GroupKFold`.

- **Conjunto de teste trancado:** cerca de 20% dos **pacientes**, com todos os seus vídeos, separados agora e não abertos até a última fase. Nenhuma escolha de parâmetro, arquitetura ou técnica pode usá-los.
- **Conjunto de desenvolvimento:** os 80% restantes, organizados em validação cruzada de cinco partes agrupadas por paciente. Toda escolha de parâmetro acontece exclusivamente aqui.
- Estratificar as divisões por origem do dado, por qualidade visual do exame e pelo **número de vídeos por paciente**, para que nenhuma parte fique só com exames fáceis nem com pacientes muito mais representados que os outros.

1.4 Hipóteses declaradas antes dos experimentos

Escrever e datar no repositório, antes de qualquer treino:

ID	Hipótese	Comparação	Métrica principal
H1	Realce clássico aumenta o contraste entre vértebra e tecido vizinho	cada técnica contra a imagem original	CNR
H2	Ganho em métrica de imagem não implica ganho na segmentação	ganho de CNR contra ganho de Dice	correlação de Spearman
H3	Redução de ruído autossupervisionada supera filtros clássicos na tarefa final	Noise2Void contra BM3D e bilateral	Dice
H4	Realce fixo não supera aumento de dados aleatório equivalente	realce determinístico contra variação aleatória de brilho e contraste	Dice
H5	Realce aprendido dentro da rede supera realce aplicado antes dela	módulo fim a fim contra melhor pipeline fixo	Dice
H6	O ganho do módulo aprendido vem do realce, não da capacidade extra	módulo de realce contra bloco convolucional neutro de mesmo tamanho	Dice
H7	Os parâmetros ótimos para a qualidade de imagem diferem dos ótimos para a tarefa	parâmetros que maximizam CNR contra os que maximizam Dice	distância no espaço de parâmetros

Declarar hipóteses antes evita o problema mais comum em trabalhos deste tipo: rodar dezenas de variações, encontrar uma que ganhou por acaso, e construir a justificativa depois.

1.5 Estimativa do ruído experimental (piloto)

Antes de comparar qualquer técnica, é preciso saber qual diferença é distinguível do acaso.

1. Treinar a rede de referência, sem nenhum pré-processamento, com cinco partes de validação cruzada e cinco sementes aleatórias, totalizando 25 execuções.
2. Calcular o desvio padrão do Dice entre sementes dentro da mesma parte. Esse valor é o **piso de ruído**.
3. **Decompor a variância da métrica em três componentes:** entre pacientes, entre vídeos do mesmo paciente e entre sementes. Isso é feito por modelo de efeitos mistos com vídeo aninhado em paciente.
4. Calcular a **diferença mínima detectável**, isto é, a menor diferença que o desenho experimental consegue afirmar com poder estatístico de 80%, usando como tamanho amostral o **número de pacientes**.

A decomposição do item 3 decide a forma da análise principal. Se os vídeos de um mesmo paciente variarem quase tanto quanto pacientes diferentes, a média por paciente esconde variabilidade real e o modelo de efeitos mistos passa a ser a análise principal. Se variarem pouco, os vídeos são praticamente réplicas do mesmo caso e a média por paciente é suficiente. É uma medida a ser feita, e não uma suposição.

O item 4 costuma surpreender: uma base com muitos vídeos, mas poucos pacientes, tem tamanho amostral pequeno. Se houver, por exemplo, duzentos vídeos vindos de sessenta pacientes, o cálculo de poder usa sessenta, e a diferença mínima detectável cresce bastante em relação ao que uma contagem por vídeo sugeriria.

Toda diferença menor que a diferença mínima detectável será reportada como inconclusiva, e não como empate nem como ganho. Se o piso de ruído for maior que dois pontos de Dice, o número de sementes precisa aumentar antes de seguir adiante.

Entrega: relatório de caracterização, arquivo de divisões congelado com hash, documento de hipóteses datado, valor da diferença mínima detectável e margem de equivalência declarada.

Protocolo transversal I — Otimização de hiperparâmetros

Este capítulo e o seguinte governam todas as fases experimentais. Nenhum resultado é reportado fora das regras definidas aqui.

A.1 O problema que este protocolo resolve

Comparar CLAHE contra BM3D usando redes com taxas de aprendizado diferentes não compara as duas técnicas: compara dois ajustes. E fixar hiperparâmetros manualmente favorece silenciosamente a configuração que foi ajustada primeiro, em geral a linha de base.

A solução é dar a cada configuração o **mesmo orçamento de busca**, conduzido por um otimizador automático, e registrar esse orçamento junto com o resultado.

A.2 Estrutura de dois níveis

Nível 1, executado uma única vez. Um estudo Optuna com 50 tentativas sobre a linha de base, sem pré-processamento, para fixar os hiperparâmetros de treino compartilhados: taxa de aprendizado, weight decay, tamanho de lote e intensidade do aumento de dados. Os valores vencedores são congelados e usados de forma idêntica por todos os braços. A justificativa é direta: a hipótese do trabalho é sobre pré-processamento, não sobre configuração de treino.

Nível 2, executado por configuração. Um estudo Optuna com orçamento idêntico de 25 tentativas para os hiperparâmetros do próprio pré-processamento. Nenhuma configuração recebe mais busca que outra. O número de tentativas e as GPU-horas consumidas entram na tabela de resultados, porque uma comparação em que um braço recebeu mais busca que o outro não é uma comparação das técnicas.

A.3 Validação cruzada aninhada

É a estrutura que impede o vazamento entre seleção de hiperparâmetro e estimativa de desempenho:

- **Conjunto de teste trancado**, com 20% dos pacientes, intocado até a Fase 7.
- **Laço externo**, com cinco partes por paciente sobre o conjunto de desenvolvimento. É o que produz a estimativa de desempenho.
- **Laço interno**, com três partes por paciente dentro da porção de treino de cada parte externa. É o único lugar onde o Optuna roda.

O Optuna nunca enxerga a parte externa. O desempenho reportado vem sempre da parte externa, e nunca do valor objetivo alcançado pelo Optuna.

Este último ponto merece destaque porque é o erro mais comum da área. O melhor valor encontrado pelo Optuna é, por construção, o máximo de dezenas de tentativas, e portanto uma estimativa otimista. Reportá-lo como desempenho do método infla o resultado de forma sistemática.

A.4 Configuração do Optuna

Item	Escolha	Motivo
Amostrador	TPE	propõe valores novos a partir dos que deram certo antes; eficiente em orçamento pequeno
Podador	Hyperband (ASHA)	interrompe tentativas ruins cedo; sem isso o custo é inviável
Armazenamento	SQLite, um estudo por configuração e parte externa	permite retomar a busca e auditar o histórico

Item	Escolha	Motivo
Semente	fixa e registrada por estudo	reprodutibilidade da busca
Relato	melhor valor e distribuição das 25 tentativas	uma configuração que só funciona com uma tentativa de sorte é frágil, e isso precisa aparecer

Reportar também o número de tentativas podadas. Uma configuração cuja maioria das tentativas foi podada cedo é instável, e isso é informação relevante sobre robustez.

A.5 Espaço de busca

Grupo	Parâmetro	Espaço	Amostragem
Treino (Nível 1)	taxa de aprendizado	10^{-5} a 10^{-2}	log-uniforme
Treino (Nível 1)	weight decay	10^{-6} a 10^{-2}	log-uniforme
Treino (Nível 1)	tamanho de lote	4, 8, 16	categórica
Treino (Nível 1)	intensidade do aumento de dados	0 a 1	uniforme
Realce (Nível 2)	limite de corte do CLAHE	1 a 5	uniforme
Realce (Nível 2)	tamanho de bloco do CLAHE	4, 8, 16, 32	categórica
Realce (Nível 2)	sigmas do filtro bilateral	espacial 1 a 9; intensidade 0,05 a 0,5	inteira e log-uniforme
Realce (Nível 2)	raio e intensidade da máscara de nitidez	0,5 a 5 e 0,1 a 2	uniforme
Realce (Nível 2)	número de quadros da média temporal	1, 3, 5, 7	categórica
Realce (Nível 2)	peso λ da perda dupla da Fase 6	10^{-2} a 1	log-uniforme

A.6 Ligação com a hipótese H7

A Fase 3 escolhe parâmetros maximizando CNR. O Optuna escolhe parâmetros maximizando Dice. São dois otimizadores com objetivos diferentes atuando sobre o mesmo espaço de busca.

Comparar os valores a que cada um converge é uma medida direta de quanto o realce que agrada o olho humano difere do realce que serve à rede. O resultado é interessante nos dois sentidos: convergência próxima valida a seleção por métrica de imagem e torna o pipeline mais barato; divergência grande mostra que otimizar qualidade visual é o critério errado para esse fim, o que é uma contribuição prática relevante para a área.

A.7 Erros a evitar, declarados no protocolo

- Rodar o Optuna sobre a parte externa de validação.
- Comparar um braço otimizado contra uma linha de base não otimizada.
- Reexecutar a busca depois de olhar o conjunto de teste.
- Reportar o valor objetivo do Optuna como desempenho do método.
- Deixar orçamentos de busca diferentes entre configurações comparadas.

Protocolo transversal II — Análise estatística

B.1 Unidade de análise

A unidade amostral é o **paciente**. Nem o quadro, nem o vídeo.

A métrica sobe pelos três níveis nesta ordem: Dice por quadro, média por vídeo, média por paciente. A média é simples em cada nível, para que um vídeo longo não pese mais que um curto, nem um paciente com cinco vídeos pese cinco vezes mais que um paciente com um só. Sem essa normalização, o resultado global passa a descrever os pacientes mais gravados, e não a população.

O tamanho amostral n que entra em todo intervalo de confiança, em todo teste e em todo cálculo de poder é o número de pacientes. Quadros do mesmo vídeo são quase idênticos, e vídeos do mesmo paciente compartilham a anatomia que está sendo segmentada; contar qualquer um dos dois como observação independente infla artificialmente a amostra e estreita os intervalos de confiança de forma enganosa.

Todas as tabelas reportam as duas contagens, o número de pacientes e o número de vídeos, para que a distinção fique explícita ao leitor.

B.2 Estimativa central e incerteza

O desenho é de cinco partes externas por três sementes aleatórias.

- O intervalo de confiança de 95% vem de ***bootstrap* de agrupamento**, com 10.000 reamostragens, sorteando **pacientes inteiros com todos os seus vídeos**, e nunca vídeos ou quadros isolados. Correção BCa aplicada ao percentil.
- Reportar a decomposição da variância em três componentes: entre pacientes, entre vídeos do mesmo paciente e entre sementes. Se a variância entre sementes dominar a variância entre configurações, a comparação de técnicas não tem base e o número de sementes precisa aumentar antes de qualquer conclusão.

B.3 Comparações pareadas

Todas as configurações rodam sobre os mesmos pacientes, então as comparações são pareadas. Para cada par formado por uma configuração e a linha de base, calcula-se a diferença por paciente e reporta-se, nesta ordem:

1. A **diferença média com intervalo de confiança de 95%**. É o resultado principal, porque o intervalo da diferença informa a magnitude e a precisão, enquanto o valor-p sozinho informa apenas se o zero foi excluído.
2. O teste de Wilcoxon pareado sobre as diferenças por paciente.
3. O tamanho de efeito pelo delta de Cliff, também com intervalo de confiança.

Modelo principal e modelo secundário. A análise principal é um modelo linear de efeitos mistos com interceptos aleatórios para paciente e para vídeo aninhado em paciente. Ele aproveita a informação de todos os vídeos sem tratá-los como independentes, e é a forma correta de lidar com o número desigual de vídeos por paciente. A análise secundária é o Wilcoxon pareado sobre as médias por paciente, mais simples, mais robusta a distribuições assimétricas e mais fácil de explicar. As duas são reportadas lado a lado. Divergência entre elas é sinal de que a estrutura aninhada está influenciando o resultado e precisa ser discutida no texto, e não escondida pela escolha do teste mais conveniente.

Como as partes da validação cruzada compartilham dados de treino, as diferenças entre partes não são independentes e o teste t comum fica otimista. Onde a comparação for feita sobre diferenças entre partes, usa-se o **t reamostrado corrigido de Nadeau e Bengio**, que ajusta a variância para levar em conta a sobreposição entre as partes.

B.4 Múltiplos testes

As famílias de teste são declaradas antes dos experimentos e recebem correções diferentes:

Família	Conteúdo	Correção
Confirmatória	hipóteses H1 a H7, declaradas na Fase 1	Holm-Bonferroni, $\alpha = 0{,}05$
Exploratória	fatorial completo, varreduras de parâmetro, análises por subgrupo	Benjamini-Hochberg, FDR $= 0{,}10$

Resultado exploratório não sustenta afirmação causal e é rotulado no texto como gerador de hipótese. Sem essa separação, com algumas dezenas de comparações, aproximadamente uma em cada vinte aparece como significativa por puro acaso.

B.5 Como afirmar que não há diferença

Um valor-p não significativo não é evidência de equivalência, é apenas ausência de evidência. Como a hipótese H4 afirma justamente uma ausência de efeito, ela exige **teste de equivalência TOST**, com margem declarada antes dos experimentos.

A margem adotada é de 1,5 ponto de Dice, ou o valor da diferença mínima detectável obtida no piloto da Fase 1, o que for maior. A conclusão de equivalência só é declarada se o intervalo de confiança da diferença estiver inteiramente contido dentro da margem.

B.6 Tabela de resultados padronizada

A mesma estrutura em todas as fases, sem colunas omitidas:

Coluna	Conteúdo
Configuração	identificador do braço experimental
n	número de pacientes, com o número de vídeos entre parênteses
Dice médio $\pm$ DP	média e desvio padrão entre pacientes
IC 95%	intervalo por *bootstrap* BCa sobre pacientes
Δ vs base	diferença média pareada
IC 95% da Δ	intervalo da diferença, resultado principal
p bruto e p corrigido	Wilcoxon pareado, antes e depois da correção
δ de Cliff	tamanho de efeito com intervalo
Tentativas e GPU-h	orçamento de busca consumido

B.7 Regras de decisão fixadas antes

- Diferença abaixo da diferença mínima detectável é reportada como inconclusiva, e não como empate nem como ganho.
- Toda execução realizada entra no relato, incluindo as que falharam ou pioraram o resultado.
- O script de análise é escrito, versionado e datado antes da abertura do conjunto de teste trancado.
- Nenhuma métrica, teste ou correção é escolhida depois de ver os resultados.

Entrega: documento de pré-registro contendo hipóteses, espaços de busca, famílias de teste, margem de equivalência e script de análise, todos versionados antes da Fase 2.

Fase 2 — Catálogo de realce clássico e seleção de parâmetros

2.1 Ajustes ponto a ponto

Cada pixel é tratado isoladamente, sem olhar os vizinhos: janelamento de intensidade por percentis, alongamento de contraste e correção gama.

2.2 Equalização de histograma

Equalização global e CLAHE (equalização adaptativa com limite de contraste). Parâmetros a varrer: tamanho do bloco e limite de corte.

2.3 Redução de ruído clássica

Filtros gaussiano, mediana, bilateral, Non-Local Means e BM3D. Os três últimos são avaliados em duas condições, com e sem transformação de Anscombe, para verificar experimentalmente se a estabilização de variância importa nesses dados.

2.4 Realce de bordas

Máscara de nitidez (*unsharp masking*), com variação de raio e intensidade.

2.5 Filtragem temporal

Média de N quadros vizinhos, sem e com compensação de movimento por fluxo óptico. A comparação entre as duas quantifica o borramento causado pelo movimento rápido da deglutição, que é o principal obstáculo para o uso de informação temporal neste problema.

2.6 Seleção de parâmetros por dois critérios concorrentes

Nenhum parâmetro é escolhido observando qual resultado ficou visualmente mais agradável. Cada técnica recebe dois conjuntos de parâmetros, obtidos por dois otimizadores com objetivos diferentes:

Critério de imagem. Estudo Optuna com 25 tentativas maximizando o CNR médio por paciente, calculado apenas no conjunto de desenvolvimento. Barato, porque não exige treinar rede alguma.

Critério de tarefa. Estudo Optuna com o mesmo orçamento de 25 tentativas maximizando o Dice, conduzido dentro do laço interno da validação cruzada aninhada, conforme o Protocolo transversal I.

Os dois conjuntos de parâmetros são congelados e seguem para as fases seguintes como braços separados. A distância entre eles no espaço de parâmetros é o teste direto da hipótese H7.

Reportar a distribuição completa das tentativas de cada estudo, e não apenas o vencedor. Se o desempenho for muito sensível ao parâmetro, isso é um resultado relevante sobre robustez, e uma técnica que só funciona em uma faixa estreita de ajuste é pior na prática que outra ligeiramente inferior porém estável.

2.7 Controles negativos e positivos

Três verificações que dão credibilidade a todas as métricas usadas depois:

Controle nulo. Aplicar a transformação identidade e rodar todo o pipeline. O resultado deve ser estatisticamente igual à linha de base. Se der diferente, existe um vazamento ou uma fonte de aleatoriedade não controlada.

Controle negativo. Aplicar borramento gaussiano forte, que sabidamente destrói informação. As métricas devem piorar. Se não piorarem, a métrica não está medindo o que se supõe.

Controle positivo sintético. Tomar quadros de melhor qualidade, adicionar ruído Poisson-gaussiano com os parâmetros estimados na Fase 1, e verificar se os filtros recuperam a imagem original. Este é o único ponto do trabalho em que existe uma referência limpa e, portanto, o único em que PSNR e SSIM são legítimos.

Entrega: módulo de pré-processamento configurável, tabela completa da varredura de parâmetros e resultados dos três controles.

Fase 3 — Avaliação da qualidade da imagem

3.1 Métricas objetivas sem referência

Como não existe imagem limpa real, PSNR e SSIM não se aplicam. O conjunto de métricas é:

- **CNR** entre a região da vértebra e o tecido adjacente, usando as máscaras já anotadas para definir as regiões. Métrica principal.
- **SNR** em região homogênea.
- **Nitidez** pela variância do Laplaciano.
- **Entropia** da imagem.
- **BRISQUE e NIQE** apenas como referência secundária, com a ressalva explícita de que foram calibradas em fotografias naturais, e não em imagens radiográficas.

Todas as métricas são calculadas por paciente, com média e intervalo de confiança obtidos por *bootstrap* sobre pacientes, nunca sobre quadros.

3.2 Avaliação subjetiva com cegamento

Desenho concreto:

- 30 quadros representativos, sorteados de forma estratificada por qualidade e por origem.
- Comparação em pares forçada, dois a dois, com a ordem esquerda/direita sorteada e a identificação da técnica oculta do avaliador.
- Pergunta única e objetiva: em qual imagem o contorno das vértebras C2 a C4 é mais nítido?
- Mínimo de três avaliadores. A participação de um fonoaudiólogo ou radiologista dá peso considerável ao resultado.

Análise: ordenação por modelo de Bradley-Terry, que transforma comparações par a par em uma escala contínua, e concordância entre avaliadores pelo W de Kendall. Concordância baixa é resultado, e não fracasso: significa que a preferência visual não é critério confiável para essa tarefa.

3.3 Análise cruzada

Correlacionar, por paciente, o ganho em CNR com a posição na ordenação subjetiva. Este é o primeiro teste da hipótese H2.

Fase 4 — Redução de ruído aprendida a partir dos próprios dados

Esta fase existe por um motivo prático forte. A base contém dezenas de milhares de quadros, dos quais apenas uma pequena fração possui anotação. Os quadros restantes são inúteis para o treino supervisionado de segmentação, mas são exatamente o que um método autossupervisionado de redução de ruído precisa. É a maneira mais direta de extrair valor dos dados não anotados.

4.1 Métodos

Noise2Void (blind-spot). Treina prevendo cada pixel a partir dos vizinhos, sem nunca ver uma imagem limpa. Supõe ruído independente entre pixels, o que é razoável para ruído quântico.

Noise2Noise entre quadros vizinhos. Dois quadros consecutivos da mesma cena são, aproximadamente, duas observações ruidosas da mesma imagem, já que o ruído quântico é independente no tempo. Após a compensação de movimento, um quadro serve de alvo para o outro. É a variante mais adequada a vídeo e conecta diretamente com a Fase 2.5.

Neighbor2Neighbor. Terceira variante, incluída por não exigir compensação de movimento.

4.2 Regras de treino

- Treinar apenas com quadros de pacientes do conjunto de desenvolvimento. Usar quadros do teste trancado, mesmo sem rótulo, é vazamento.
- Arquitetura pequena e fixa (U-Net rasa), a mesma para as três variantes, de modo que a comparação isole o critério de treino e não a capacidade do modelo.
- Registrar tempo de treino e número de parâmetros.

4.3 Avaliação

Três eixos, nesta ordem:

1. Controle positivo sintético com referência conhecida, em que PSNR e SSIM são legítimos.
2. CNR nos dados reais.
3. Desempenho final na segmentação, que é o critério que decide.

4.4 Risco específico a monitorar

Métodos autossupervisionados tendem a suavizar estruturas de baixo contraste junto com o ruído. A verificação é inspecionar o **mapa de resíduo**, isto é, a diferença entre entrada e saída. Se o resíduo contiver contorno anatômico visível, o método está removendo sinal, e não apenas ruído. Esse diagnóstico deve ser reportado para cada variante.

Fase 5 — Impacto na segmentação, com desenho fatorial

Modelo de referência fixo: U-Net treinada apenas com os quadros anotados, para segmentar as vértebras C2 a C4. A arquitetura não muda nesta fase. A variável em estudo é o pré-processamento.

5.1 Desenho fatorial

Testar apenas algumas combinações escolhidas por intuição é o caminho mais rápido para um resultado não reproduzível. Em vez disso, adota-se um desenho fatorial completo $2 \times 2 \times 2$ com três fatores binários:

Fator	Nível 0	Nível 1
A: redução de ruído	ausente	melhor método da Fase 2 ou 4
B: equalização	ausente	CLAHE com parâmetro congelado
C: realce de bordas	ausente	máscara de nitidez congelada

São oito combinações. Cada uma roda em cinco partes e três sementes, totalizando 120 execuções.

A análise usa **modelo linear de efeitos mistos**, com paciente como efeito aleatório e os três fatores mais suas interações como efeitos fixos. Isso responde diretamente a duas perguntas que a escolha manual não responde: qual fator contribui isoladamente, e se existe interação, ou seja, se a combinação vale mais ou menos que a soma das partes.

A **ordem das operações**, reduzir ruído antes ou depois de equalizar, entra como fator adicional aplicado apenas às combinações em que A e B estão ambos ativos.

5.2 Modo de aplicação

Duas condições, cruzadas com o melhor resultado do fatorial:

- **Determinístico:** a mesma transformação aplicada a treino, validação e teste.
- **Estocástico:** a transformação aplicada com parâmetro sorteado a cada época, funcionando como aumento de dados.

A comparação obrigatória para a hipótese H4 é contra a variação aleatória de brilho e contraste com amplitude equivalente. Se o CLAHE fixo não superar essa variação aleatória, a conclusão prática é que não há motivo para o pré-processamento, e isso precisa ser reportado com a mesma clareza de um resultado positivo.

5.3 Condições de treino idênticas

Mesmo otimizador, mesma taxa de aprendizado, mesmo orçamento de épocas, mesmo critério de parada antecipada avaliado na validação interna, e mesma normalização final de intensidade após o realce. Sem isso, a diferença medida pode ser apenas efeito de uma configuração ter recebido treino mais favorável.

5.4 Métricas

- **Dice e IoU**, que medem sobreposição.
- **Distância média entre superfícies e Hausdorff 95**, que medem erro de contorno.
- **Erro na medida clínica C2 a C4, em milímetros.** É a métrica que traduz o resultado para a aplicação real e deve ser reportada como métrica principal, ao lado do Dice.

Todas são agregadas por paciente antes da média geral, para que pacientes com mais quadros anotados não dominem o resultado.

5.5 Análise estatística e orçamento computacional

A análise segue integralmente o Protocolo transversal II, sem exceção. O fatorial pertence à família exploratória e recebe correção por Benjamini-Hochberg; as comparações que testam H3, H4 e H5 pertencem à família confirmatória e recebem Holm-Bonferroni. A conclusão de H4 exige teste de equivalência TOST com a margem declarada na Fase 1.

Orçamento computacional desta fase:

Item	Contagem
Configurações do fatorial	8
Partes externas por configuração	5
Sementes por parte	3
Execuções finais	120
Tentativas Optuna no laço interno	$8 \times 5 \times 25 = 1.000$
Custo efetivo com poda Hyperband	aproximadamente 300 execuções completas

A poda não é um detalhe de eficiência: sem ela o orçamento desta fase é inviável. Registrar as GPU-horas efetivamente gastas por configuração e incluí-las na tabela de resultados.

Fase 6 — Realce aprendido dentro da rede de segmentação

A pergunta desta fase é diferente de todas as anteriores. Em vez de escolher o melhor realce por critério humano ou por métrica de imagem, deixa-se a própria rede aprender qual transformação de intensidade favorece a segmentação. O realce deixa de ser etapa anterior e passa a ser parte do modelo, treinada com o mesmo gradiente.

6.1 Variantes, da mais simples à mais complexa

V1 — Camada paramétrica diferenciável. Uma camada com pouquíssimos parâmetros aprendíveis: nível e largura de janela, e expoente gama. Aprende junto com a segmentação. A vantagem científica é grande, porque os parâmetros aprendidos podem ser comparados numericamente com os escolhidos manualmente na Fase 2. Se a rede convergir para valores próximos, isso valida a seleção manual. Se convergir para valores muito diferentes, isso indica que o critério visual e o critério da tarefa divergem, o que reforça a hipótese H2.

V2 — Módulo convolucional raso de realce. Três a cinco camadas convolucionais com conexão residual, colocadas antes da U-Net e treinadas apenas com a perda de segmentação. Mais expressivo e menos interpretável que V1.

V3 — Redutor de ruído autossupervisionado acoplado. A rede da Fase 4 é conectada à entrada da U-Net em duas condições: pesos congelados, e ajuste fino conjunto. A comparação entre as duas mede quanto o critério de redução de ruído diverge do critério da tarefa.

V4 — Treino conjunto com duas perdas. Perda de segmentação somada à perda autossupervisionada de redução de ruído, com peso λ variando em $\{0{,}1;\ 0{,}5;\ 1{,}0\}$. Mede se manter o objetivo de redução de ruído ativo regulariza o modelo ou compete com a segmentação.

6.2 Controle de capacidade

Qualquer módulo adicionado aumenta o número de parâmetros da rede. Um ganho pode vir apenas dessa capacidade extra, sem relação alguma com realce. O controle é rodar uma U-Net com um bloco convolucional neutro na entrada, com número de parâmetros equivalente ao módulo de realce, sem qualquer semântica de realce e sem inicialização especial.

Somente se o módulo de realce superar esse controle a conclusão da hipótese H5 se sustenta. Sem esse controle, o resultado não é interpretável.

6.3 Interpretação do que foi aprendido

- Visualizar a saída do módulo aprendido em quadros de teste.
- Medir o CNR da saída do módulo e comparar com o CNR do CLAHE e do BM3D. A pergunta é se a rede convergiu para algo parecido com o realce clássico ou para algo diferente.
- Para V1, plotar a curva de transferência de intensidade aprendida e sobrepor à curva do gama escolhido manualmente.
- Para V2 e V3, inspecionar o mapa de resíduo em busca de estrutura anatômica removida.

Esta análise é o que transforma a fase de "a rede ficou melhor" em contribuição científica: mostra **o que** o realce ótimo para a tarefa realmente é, e se ele coincide com o realce ótimo para o olho humano.

6.4 Avaliação

Mesmo protocolo da Fase 5: cinco partes, três sementes, mesmas métricas e mesma correção estatística. As variantes V1 a V4 entram na mesma família de comparações e recebem a mesma correção para múltiplas comparações.

Fase 7 — Teste final, síntese e escrita

Abertura do conjunto trancado. Apenas as três configurações finalistas, escolhidas exclusivamente pelo conjunto de desenvolvimento, são avaliadas nos pacientes reservados. Uma única passagem, sem retorno. Se o resultado no teste trancado divergir do desenvolvimento, isso é reportado como está e discutido, e não corrigido pela escolha de outra finalista.

Síntese das três avaliações. Métrica objetiva de imagem, preferência humana cega e desempenho na tarefa, reunidas em uma tabela única que mostra se as três ordenações concordam.

Análise de falhas. Identificar em que subgrupo cada técnica prejudicou o resultado. A hipótese a testar é que o realce ajuda nos exames de baixa qualidade e atrapalha nos já bem expostos, o que sugeriria pré-processamento adaptativo em vez de uniforme.

Custo computacional. Tempo por quadro de cada opção, já que a aplicação final processa vídeos inteiros.

Recomendação final do pipeline de pré-processamento, com a incerteza declarada.

Ordem de execução e prioridade de cortes

A sequência de execução é a seguinte:

Ordem	Etapa
1	Fase 0 — Preparação
2	Fase 1 — Caracterização da base e congelamento do protocolo
3	Protocolos transversais I e II — arcabouço Optuna aninhado e script de análise
4	Fase 2 — Catálogo de realce clássico
5	Fase 3 — Avaliação da qualidade da imagem
6	Fase 4 — Redução de ruído aprendida
7	Fase 5 — Impacto na segmentação
8	Fase 6 — Realce aprendido dentro da rede
9	Fase 7 — Teste final, síntese e escrita

As etapas 1 a 3 são pré-requisito de tudo o que vem depois, porque definem a divisão dos dados, as hipóteses e o arcabouço de análise. As etapas 5 e 6 podem ser conduzidas em paralelo, já que a avaliação de qualidade de imagem não depende do treino das redes de redução de ruído.

Se o escopo precisar encolher, a ordem de corte é: reduzir o fatorial de 2^3 para uma fração de meio, reduzir o orçamento de busca de 25 para 15 tentativas de forma igual em todos os braços, remover a variante V4 e depois a V3 na Fase 6, e reduzir o número de avaliadores subjetivos.

O que não pode ser cortado em nenhuma hipótese: o agrupamento por paciente, o conjunto de teste trancado, o aninhamento da busca de hiperparâmetros, a igualdade de orçamento entre braços, as múltiplas sementes, os controles de capacidade e a correção para múltiplas comparações. Cortar qualquer um deles não economiza trabalho, apenas produz um resultado que não se sustenta.

Riscos e mitigação

Risco	Sinal de alerta	Mitigação
Diferenças menores que o ruído entre sementes	piso de ruído acima de dois pontos de Dice no piloto	aumentar o número de sementes e reportar como inconclusivo em vez de forçar conclusão
Vazamento entre treino e teste	desempenho anormalmente alto	agrupamento por paciente congelado com hash na Fase 1
Vídeos do mesmo paciente em partes diferentes	desempenho alto em pacientes com muitos vídeos	chave de grupo pelo identificador do paciente e conferência automática antes de cada treino
Paciente duplicado entre as bases	dois registros com anatomia idêntica	verificação de duplicatas na Fase 1, antes da divisão
Tamanho amostral superestimado	intervalos de confiança estreitos demais	n igual ao número de pacientes em todo cálculo; *bootstrap* de agrupamento
Redutor de ruído removendo anatomia	contorno visível no mapa de resíduo	diagnóstico obrigatório de resíduo em toda variante da Fase 4
Ganho da Fase 6 vindo de capacidade extra	módulo grande vencendo por margem pequena	controle de capacidade neutro, obrigatório
Explosão combinatória de experimentos	perda de rastreabilidade das execuções	grades e hipóteses declaradas na Fase 1; execuções fora do protocolo marcadas como exploratórias e excluídas das conclusões
Escolha do vencedor pelo conjunto de teste	teste consultado antes da Fase 7	conjunto trancado, com uma única abertura
Vazamento pela busca de hiperparâmetros	desempenho reportado igual ao valor objetivo do Optuna	validação cruzada aninhada; desempenho sempre vindo da parte externa
Comparação injusta entre braços	um braço com mais tentativas que outro	orçamento de busca idêntico, registrado na tabela de resultados
Conclusão de ausência de efeito sem base	valor-p não significativo lido como equivalência	teste TOST com margem declarada antes dos experimentos
Custo computacional inviável	fila de execuções sem previsão de término	poda Hyperband obrigatória e orçamento contabilizado por fase

Entregas por fase

Fase	Entrega principal
0	Pipeline de leitura de vídeo e documento de definição do problema
1	Protocolo congelado, hipóteses datadas e diferença mínima detectável
I e II	Arcabouço Optuna aninhado, script de análise estatística e pré-registro
2	Módulo de pré-processamento configurável e resultados dos controles
3	Métricas de qualidade e ordenação subjetiva cega

Fase	Entrega principal
4	Redutores de ruído autossupervisionados e diagnóstico de resíduo
5	Análise fatorial do impacto na segmentação
6	Comparação entre realce fixo e realce aprendido fim a fim
7	Avaliação no conjunto trancado e recomendação final